



МИНИСТЕРСТВО ПРОСВЕЩЕНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«РОССИЙСКИЙ ГОСУДАРСТВЕННЫЙ ПЕДАГОГИЧЕСКИЙ
УНИВЕРСИТЕТ им. А. И. ГЕРЦЕНА»

**ИНСТИТУТ ИНФОРМАЦИОННЫХ ТЕХНОЛОГИЙ И
ТЕХНОЛОГИЧЕСКОГО ОБРАЗОВАНИЯ**
Кафедра информационных технологий и электронного обучения

Основная профессиональная образовательная программа
Направление подготовки 09.03.01 Информатика и вычислительная техника
Направленность (профиль) «Технологии разработки программного обеспечения»
форма обучения – очная

ОБЗОР ИСТОЧНИКОВ
по теме
«Интеллектуальные системы обучения»

Обучающегося 4 курса
Клементьева Алексея Александровича

Санкт-Петербург
2024

Оглавление

ВВЕДЕНИЕ	3
Историческое развитие и основы Q-Learning в интеллектуальных системах обучения	4
Deep Q-Learning и современные подходы	5
Прогнозирование успеваемости и поведенческие модели студентов	6
Модели образовательной среды	7
Educational Data Mining и Learning Analytics в построении интеллектуальной системы обучения	9
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	11

ВВЕДЕНИЕ

Интеллектуальные системы обучения (ИСО) представляют собой важный элемент современного образовательного процесса, обеспечивая индивидуализированный подход к обучению и адаптацию образовательного контента под потребности каждого студента. Подчеркивается [1], что актуальность этих систем в образовательной среде обусловлена необходимостью повышения качества образования, а также адаптации к быстро меняющимся требованиям рынка труда и технологическим изменениям. Автор указывает, что ИСО играют ключевую роль в цифровой трансформации образования, особенно в условиях пандемии COVID-19, когда многие учреждения были вынуждены перейти на дистанционное обучение. Левин подчеркивает, что эффективные онлайн-платформы, поддерживающие качество образовательного процесса, становятся неотъемлемой частью современного обучения.

Дополнительно, авторы [2] выделяют необходимость внедрения ИСО как части общего тренда цифровой трансформации. Они отмечают, что такие системы позволяют не только оптимизировать процесс обучения, но и улучшить взаимодействие между студентами и преподавателями. В исследовании рассматривается потенциал ИСО для обеспечения непрерывного образовательного процесса в цифровую эпоху, акцентируя внимание на их роли в интеграции традиционных и дистанционных форм обучения.

Основные цели ИСО заключаются в создании адаптивной образовательной среды, которая учитывает индивидуальные особенности учащихся. Авторы [3] описывают применение адаптивных цифровых технологий в преподавании, подчеркивая, что такие системы способствуют повышению мотивации студентов и улучшению качества усвоения материала. В их работе подробно анализируется использование адаптивных технологий для учета уровня знаний студентов и предоставления соответствующих заданий. Это, по мнению авторов, способствует более глубокому пониманию предмета, а также позволяет преподавателям мониторить успеваемость и своевременно корректировать образовательные стратегии.

В разработке ИСО применяются разнообразные методы и технологии, включая машинное обучение, анализ больших данных и когнитивные модели. В исследованиях, упомянутых Космодемьянской и её коллегами, рассматриваются примеры использования нейронных сетей для мониторинга успеваемости студентов. Авторы подчеркивают, что эти технологии помогают выявлять закономерности в обучении и предоставлять персонализированные рекомендации. Важность виртуальных образовательных моделей

также подчеркивается в их работе, где указывается, что интерактивные элементы и игровые методы обучения обеспечивают более высокий уровень вовлеченности учащихся.

Историческое развитие и основы Q-Learning в интеллектуальных системах обучения

Q-Learning, как один из методов обучения с подкреплением, представляет собой мощный инструмент для создания адаптивных и эффективных интеллектуальных систем обучения. Этот метод, впервые представленный Уоткинсом в 1989 году, получил широкое распространение в образовательных технологиях благодаря своей способности моделировать процесс принятия решений учащимися. Авторы подчеркивают, что базовая концепция Q-Learning основана на применении Q-функции для оценки качества действий, предпринимаемых агентом в различных состояниях [4].

Агент в контексте Q-Learning взаимодействует с окружающей средой, получает вознаграждение за свои действия и обновляет свои оценки на основе полученного опыта. В образовательных системах этот подход позволяет моделировать процесс обучения студентов, адаптируя учебные материалы и задания на основе их предыдущих успехов и ошибок. Исследования демонстрируют, как Q-Learning используется для определения уровня знаний учащихся и адаптации учебного процесса с учетом контекстуальной информации [5].

Применение Q-Learning в образовательных технологиях началось с разработки систем, которые автоматически подстраивают учебный процесс под индивидуальные потребности студентов. В частности, авторы отмечают использование Q-Learning для создания учебных пособий и тренажеров, адаптирующихся к уровню знаний учащихся. Этот подход обеспечил значительные улучшения в персонализации учебного процесса, что делает его особенно актуальным в современных образовательных технологиях [4].

С течением времени классический Q-Learning был усовершенствован за счет интеграции методов глубокого обучения, что позволило системам обрабатывать более сложные данные и предоставлять более точные рекомендации. В работе Пашкина и Левашовой (2008) акцентируется внимание на внедрении многоагентных моделей, которые улучшают адаптивность систем и учитывают социальные аспекты взаимодействия студентов. Это обеспечивает создание более динамичной и интерактивной учебной среды, которая способствует не только индивидуальному, но и коллективному обучению [5].

Deep Q-Learning и современные подходы

Глубокое Q-Learning (DQN) представляет собой мощный инструмент в области обучения с подкреплением, который объединяет методы глубокого обучения с классическими алгоритмами Q-Learning. Это позволяет эффективно решать задачи, связанные с большими пространствами состояний и действиями. Исследования DeepMind, включая использование DQN в адаптивных обучающих системах, показывают его высокую эффективность для автоматической персонализации учебного материала, что позволяет системе адаптироваться к потребностям учащихся на основе их взаимодействия с материалом [6].

Глубокое обучение использует нейронные сети для автоматического извлечения признаков из данных, что делает его особенно полезным для задач с высокой размерностью, таких как обработка изображений и последовательностей. В контексте Q-Learning нейронные сети используются для аппроксимации Q-функции, что позволяет агенту принимать более обоснованные решения на основе сложных входных данных. Для реализации DQN применяются различные архитектуры нейронных сетей. Полносвязные нейронные сети (DNN) используются в простых задачах, где данные имеют фиксированную размерность. Сверточные нейронные сети (CNN) эффективны для обработки изображений и пространственных данных, что позволяет агентам воспринимать визуальную информацию [7]. Рекуррентные нейронные сети (RNN) применяются в задачах, где важен контекст и последовательность данных, например, в играх или временных рядах [8].

Для повышения стабильности обучения в DQN были внедрены такие техники, как Target networks, которые уменьшают корреляцию между целевыми и текущими значениями Q-функции. Современные исследования приводят к различным модификациям DQN. Distributional Q-Learning оценивает распределение вероятностей наград вместо одной ожидаемой награды, что позволяет более точно моделировать неопределенности [8]. Dueling DQN разделяет оценку ценности состояния и действия, что позволяет лучше различать важность различных действий в одном состоянии [9]. Multi-Agent Q-Learning применяется в групповых обучающих средах, где несколько агентов взаимодействуют друг с другом и окружающей средой [10].

Эксперименты демонстрируют высокую эффективность DQN и его модификаций в различных областях. В управлении трафиком использование D4QN_PEN для управления сигналами светофоров на основе многомерной информации о трафике продемонстрировало улучшение по сравнению с традиционными методами [8]. В распределении ресурсов

многоагентные системы Dueling Double Deep Q-Network показали хорошие результаты в управлении ресурсами в условиях высокой мобильности.

Прогнозирование успеваемости и поведенческие модели студентов

Прогнозирование успеваемости и поведенческих моделей студентов является важной частью интеллектуальных систем обучения. В данном разделе рассматриваются ключевые модели и методы, которые используются для предсказания успеваемости студентов и анализа их поведения в процессе обучения.

Одной из наиболее популярных моделей для прогнозирования успеваемости является Bayesian Knowledge Tracing (BKT), которая используется для отслеживания уровня знаний студентов на основе их предыдущих ответов. Исследования показали, что BKT эффективно помогает адаптировать учебный процесс, что способствует улучшению успеваемости студентов. Например, в одном из исследований было доказано, что система, основанная на BKT, привела к улучшению результатов студентов, что подтверждается статистическими данными о росте их успеваемости [11].

Другим методом оценки успеваемости является Performance Factor Analysis (PFA), который учитывает сложность заданий. Этот подход позволяет более точно прогнозировать будущие результаты студентов, принимая во внимание различные факторы, такие как уровень сложности учебных материалов и индивидуальные особенности учащихся. Аналогично, Deep Knowledge Tracing (DKT), использующий рекуррентные нейронные сети, предоставляет возможности для анализа образовательных траекторий студентов, что позволяет предсказать их дальнейшие успехи, моделируя более сложные зависимости в их взаимодействии с материалом.

Методы оценки поведения студентов играют важную роль в предсказании их успешности и вовлеченности. Одним из таких методов является использование скрытых марковских моделей (Hidden Markov Models), которые позволяют прогнозировать поведенческие паттерны студентов, такие как списывание или угадывание ответов. Этот подход способствует выявлению потенциальных случаев академической недобросовестности и разработке стратегий для их предотвращения [12]. Также важным инструментом является Log Data Mining, который помогает анализировать поведенческие паттерны студентов для оценки их мотивации и вовлеченности в учебный процесс. Эти методы позволяют создавать адаптивные образовательные среды, которые способствуют поддержанию интереса студентов и увеличению их активности.

Интеграция моделей прогнозирования в системы обучения позволяет динамически адаптировать учебный процесс. Модели предсказания успеваемости могут быть

использованы для регулирования скорости и объема материала, что позволяет подстраивать обучение под индивидуальные потребности студентов. Прогнозы, полученные с помощью этих моделей, могут служить основой для создания персонализированных учебных траекторий, которые будут учитывать сильные и слабые стороны учащихся, что способствует более эффективному обучению.

Одним из успешных примеров внедрения таких технологий является использование модели ВКТ в системе Cognitive Tutor. Эта система адаптирует обучение математике, позволяя студентам осваивать материал в своем собственном темпе, что способствует улучшению их учебных результатов. Еще одним примером является применение DKT в онлайн-платформах, таких как EdX, где система анализирует взаимодействие студентов с учебным материалом и адаптирует содержание курсов в соответствии с их потребностями, что способствует повышению качества обучения и улучшению результатов студентов [13][14].

Модели образовательной среды

Прогнозирование образовательной среды представляет собой ключевое направление в развитии интеллектуальных систем обучения. Этот процесс включает в себя использование различных методов моделирования для оптимизации учебного процесса, адаптации учебных материалов и формирования индивидуализированных траекторий обучения, что способствует более эффективному усвоению знаний.

Одним из подходов моделирования учебных материалов и траекторий является использование graph-based моделей, таких как Knowledge Space Theory. Эти модели представляют знания как граф, где узлы отражают концепты или темы, а ребра — связи между ними. Применение этой теории позволяет выявить структуры знаний студентов, определить пробелы и спланировать их обучение с учетом индивидуальных особенностей. Например, Knowledge Space Theory может быть использована для того, чтобы сформировать последовательность изучаемых тем, оптимальную для достижения определенного уровня компетенции, а также для анализа и коррекции образовательных траекторий студентов, обеспечивая более точное планирование образовательного процесса [15].

В дополнение к graph-based моделям, широко применяются методы тематического моделирования, такие как Latent Dirichlet Allocation (LDA) и Non-negative Matrix Factorization (NMF). Эти методы позволяют автоматизировать классификацию учебных материалов, выделяя ключевые темы и структуру документации, что значительно облегчает работу преподавателей. Например, LDA и NMF помогают анализировать содержание учебных материалов и автоматически выделять важные категории, которые могут быть

использованы для формирования учебных планов. Это позволяет преподавателям более эффективно выбирать материалы для занятий и быстрее адаптировать содержание курсов в зависимости от потребностей студентов, повышая таким образом их вовлеченность и мотивацию [16].

Системы рекомендаций играют важную роль в прогнозировании следующих шагов в обучении студентов. Методы Collaborative Filtering, используемые в этих системах, анализируют предпочтения студентов на основе их взаимодействия с учебным материалом и предыдущими заданиями. Это позволяет предлагать наиболее подходящие задания, тем самым улучшая процесс обучения за счет персонализированного подхода. Внедрение таких систем значительно повышает эффективность обучения, так как они могут адаптировать учебный процесс под конкретного студента, исходя из его предыдущих успехов и предпочтений.

Прогнозирование сложности заданий также является важным аспектом образовательной среды. Модели Item Response Theory (IRT) используются для объективной оценки сложности заданий и уровня знаний студентов [7]. IRT помогает определить, насколько правильно студент решает задачи разной сложности, и позволяет точно оценить его способности. Это предоставляет более глубокое понимание уровня подготовки учащегося, независимо от сложности самих заданий, что является важным для оптимизации образовательных траекторий и оценки прогресса студентов.

Factorization Machines представляют собой еще один мощный инструмент для персонализации сложности задач. Эти модели могут учитывать взаимодействие различных факторов, таких как уровень знаний студента и сложность заданий, что позволяет адаптировать образовательный процесс к индивидуальным особенностям каждого ученика. Они обеспечивают более точную настройку образовательного контента, помогая избегать как излишне легких, так и чрезмерно сложных заданий, что способствует более эффективному обучению.

Использование Q-Learning в образовательной среде позволяет оптимизировать траектории обучения, основываясь на принципах обучения с подкреплением. Этот метод позволяет обучающим системам выбирать оптимальные действия, такие как предложение следующего материала, с учетом предыдущих результатов студента. Реализация награды за правильный выбор следующего материала способствует мотивации учащихся и увеличивает их вовлеченность в учебный процесс. Внедрение Q-Learning в системы адаптивного обучения помогает обеспечить непрерывное улучшение образовательного процесса, основываясь на обратной связи с пользователем.

Интеграция этих методов в образовательные системы предоставляет возможность для создания высокоэффективных и персонализированных образовательных траекторий. Системы, использующие такие подходы, способны динамически адаптировать учебные материалы и задания, что способствует более точному удовлетворению потребностей каждого студента и улучшению качества обучения в целом.

Educational Data Mining и Learning Analytics в построении интеллектуальной системы обучения

Образовательный анализ данных (Educational Data Mining, EDM) и аналитика обучения (Learning Analytics) играют важную роль в оптимизации учебных процессов и улучшении образовательных результатов. Основные цели EDM включают выявление скрытых закономерностей в образовательных данных, что позволяет улучшить учебный процесс на основе точных и обоснованных данных. Применение алгоритмов машинного обучения для анализа больших объемов данных помогает не только улучшить текущие образовательные практики, но и способствует персонализации обучения, предоставляя студентам материалы и задания, соответствующие их потребностям и уровням знаний. Например, в исследованиях, посвященных прогнозированию успеваемости студентов, использование алгоритмов, таких как деревья решений, случайный лес и градиентный бустинг, позволило достичь значительных успехов в предсказании академической успеваемости и других поведенческих факторов учащихся [17].

Существуют различные методы кластеризации, такие как K-Means, DBSCAN и иерархическая кластеризация, которые применяются для группировки студентов по определенным признакам, что также способствует индивидуализации подхода к обучению. Современные инструменты для анализа образовательных данных включают Python-библиотеки, такие как Pandas и Scikit-learn, а также специализированные платформы, такие как RapidMiner и Weka, которые предоставляют удобные интерфейсы для выполнения сложных анализов и визуализаций образовательных данных [18]. Эти инструменты позволяют исследовать не только данные об успеваемости, но и поведение студентов, выявляя паттерны, которые могут указывать на необходимость изменений в образовательных стратегиях и методах преподавания.

Одним из примеров использования EDM является прогнозирование отсева студентов в онлайн-курсах, где аналитика данных используется для выявления факторов, способствующих уходу студентов с курса. Это помогает разработать стратегии вмешательства, направленные на улучшение удержания студентов и оптимизацию учебных программ [19]. Важно отметить, что использование EDM тесно связано с методами

обучения с подкреплением, такими как Q-Learning, что открывает новые возможности для персонализации образовательного процесса. Применение EDM для формирования наградной функции в Q-Learning позволяет создавать более эффективные и адаптивные образовательные среды. Взаимосвязь между EDM и Q-Learning заключается в использовании аналитики данных для предварительной обработки информации, которая затем используется для оптимизации траекторий обучения студентов. Эта интеграция может улучшить качество образовательного процесса и повысить мотивацию учащихся.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Левин С.М. Дистанционное обучение на волне пандемии // Инновационные научные исследования: сетевой журнал. – 2021. – № 5-2(7). – С. 243-250. URL: <https://ip-journal.ru/> (Дата обращения: 25.12.2024)
2. Ачмизова, С. Я. Образование в эпоху цифровой трансформации: новые пути и горизонты / С. Я. Ачмизова, З. М. Казиева, Я. Н. Сириева // Экономика и предпринимательство. – 2023. – № 9(158). – С. 570-574. – DOI 10.34925/EIP.2023.158.09.105. – EDN ZWQPAQ.
3. Космодемьянская С. С., Низамов И. Д., Муринова Д. И., Саттарова Г. А. Применение адаптивных цифровых технологий в преподавании химии // Бизнес. Образование. Право. 2022. № 3 (60). С. 360—365. DOI: 10.25683/VOLBI.2022.60.328.
4. Еремеев А. П., Кожухов А. А., Голенков В. В., Гулякина Н. А. О реализации средств машинного обучения в интеллектуальных системах реального времени // Международный журнал «Программные продукты и системы». – 2018. – URL: <https://swsys.ru/index.php?page=article&id=4451> (Дата обращения: 25.12.2024).
5. Пашкин М. П., Левашова Т. В. Использование контекста при определении уровня знаний учащихся в многоагентных интеллектуальных системах дистанционного обучения // Труды СПИИРАН. Вып. 6. — СПб.: Наука, 2008.
6. Ji Y., Wang Y., Zhao H., Gui G., Gaćanin H., Sari H., Adachi F. Multi-Agent Reinforcement Learning Resources Allocation Method Using Dueling Double Deep Q-Network in Vehicular Networks // IEEE Transactions on Vehicular Technology. 2023. Vol. 72. P. 13447–13460. URL: <https://ieeexplore.ieee.org/document/10123947> (Дата обращения: 25.12.2024).
7. Gholizadeh N., Kazemi N., Musilek P. A Comparative Study of Reinforcement Learning Algorithms for Distribution Network Reconfiguration With Deep Q-Learning-Based Action Sampling // IEEE Access. 2023. Vol. 11. P. 13714–13723. URL: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=10040655> (Дата обращения: 25.12.2024).
8. Y. He, C. Mu and Y. Sun, «Enhancing Intersection Signal Control: Distributional Double Dueling Deep Q-learning Network with Priority Experience Replay and NoisyNet Approach» 2023 19th International Conference on Mobility, Sensing and Networking (MSN), Nanjing, China, 2023, pp. 794-799, doi: 10.1109/MSN60784.2023.00116
9. Q. Wang, X. Wang, M. Gao, X. Luo, Y. Li and H. Zhang, "Fully Parameterized Dueling Mixing Distributional Q-Learning for Multi-Agent Cooperation," 2022 IEEE 34th International Conference on Tools with Artificial Intelligence (ICTAI), Macao, China, 2022, pp. 1147-1151, doi: 10.1109/ICTAI56018.2022.00175.
10. Mishra K., Rajareddy G. N. V., Ghugar U., Chhabra G. S., Gandomi A. H. A Collaborative Computation and Offloading for Compute-Intensive and Latency-Sensitive Dependency-Aware Tasks in Dew-Enabled Vehicular Fog Computing: A Federated Deep Q-Learning Approach // IEEE Transactions on Network and Service Management. 2023. Vol. 20. P. 4600-4614. URL: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=10143987> (Дата обращения: 25.12.2024).
11. Takami K., Flanagan B., Dai Y., Ogata H. Evaluating the Effectiveness of Bayesian Knowledge Tracing Model-Based Explainable Recommender // Int. J. Distance Educ. Technol. – 2024. – Vol. 22. – P. 1-23. URL: <https://www.igi-global.com/gateway/article/337600> (Дата обращения: 25.12.2024).
12. Lhutfi I., Hardiana R. D., Mardiani R. Fraud Pentagon Model: Predicting Student's Cheating Academic Behavior // Jurnal ASET (Akuntansi Riset). – 2021. URL: <https://ejournal.upi.edu/index.php/aset/article/view/40331> (Дата обращения: 25.12.2024).

13. Lee M. P., Croteau E. A., Gurung A., Botelho A. F., Heffernan N. T. Knowledge Tracing Over Time: A Longitudinal Analysis // Educational Data Mining. – 2023. URL: <https://educationaldatamining.org/EDM2023/proceedings/2023.EDM-short-papers.28/2023.EDM-short-papers.28.pdf> (Дата обращения: 25.12.2024).
14. Zhang Q., Yang D., Fang P., Liu N., Zhang L. Develop Academic Question Recommender Based on Bayesian Network for Personalizing Student's Practice // Int. J. Emerg. Technol. Learn. – 2020. – Vol. 15. – P. 4-19. URL: <https://api.semanticscholar.org/CorpusID:222260100> (Дата обращения: 25.12.2024).
15. de Chiusole, D., Stefanutti, L., Anselmi, P., & Robusto, E. (2020). Stat-Knowlab. Assessment and Learning of Statistics with Competence-based Knowledge Space Theory. International Journal of Artificial Intelligence in Education, 30(4), 668-700. <https://link.springer.com/article/10.1007/s40593-020-00223-1> (Дата обращения: 25.12.2024).
16. Shao X, Li C, Yang H, Lu X, Liao J, Qian J, Wang K, Cheng J, Yang P, Chen H, Xu X, Fan X. Knowledge-graph-based cell-cell communication inference for spatially resolved transcriptomic data with SpaTalk. Nat Commun. 2022 Jul 30;13(1):4429. doi: 10.1038/s41467-022-32111-8. PMID: 35908020; PMCID: PMC9338929.
17. Yagcı, M. Educational data mining: prediction of students' academic performance using machine learning algorithms / M. Yagcı. — Smart Learning Environments, 2022. — Vol. 9. — URL: <https://slejournal.springeropen.com/articles/10.1186/s40561-022-00192-z> (Дата обращения: 25.12.2024).
18. Guleria, P. Explainable AI and machine learning: performance evaluation and explainability of classifiers on educational data mining inspired career counseling / P. Guleria, M. Sood. — Education and Information Technologies, 2022. — Vol. 28. — P. 1081–1116. — URL: <https://link.springer.com/article/10.1007/s10639-022-11221-2> (Дата обращения: 25.12.2024).
19. Shafiq, D. Student Retention Using Educational Data Mining and Predictive Analytics: A Systematic Literature Review / D. Shafiq, M. Marjani, R. A. Ariyaluran Habeeb, D. Asirvatham. — IEEE Access, 2022. — Vol. 10. — P. 72480–72503. — URL: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=9815588> (Дата обращения: 25.12.2024).